

3. Neural Networks

박인건

qkrdlsrjs00@g.skku.edu

TNT ML Team

2024/09/19



Contents

- Introduction
- Neural Networks
- TensorFlow
- AGI (Artificial General Intelligence)
- Paper Review

Introduction

1주차 : 신경망 >

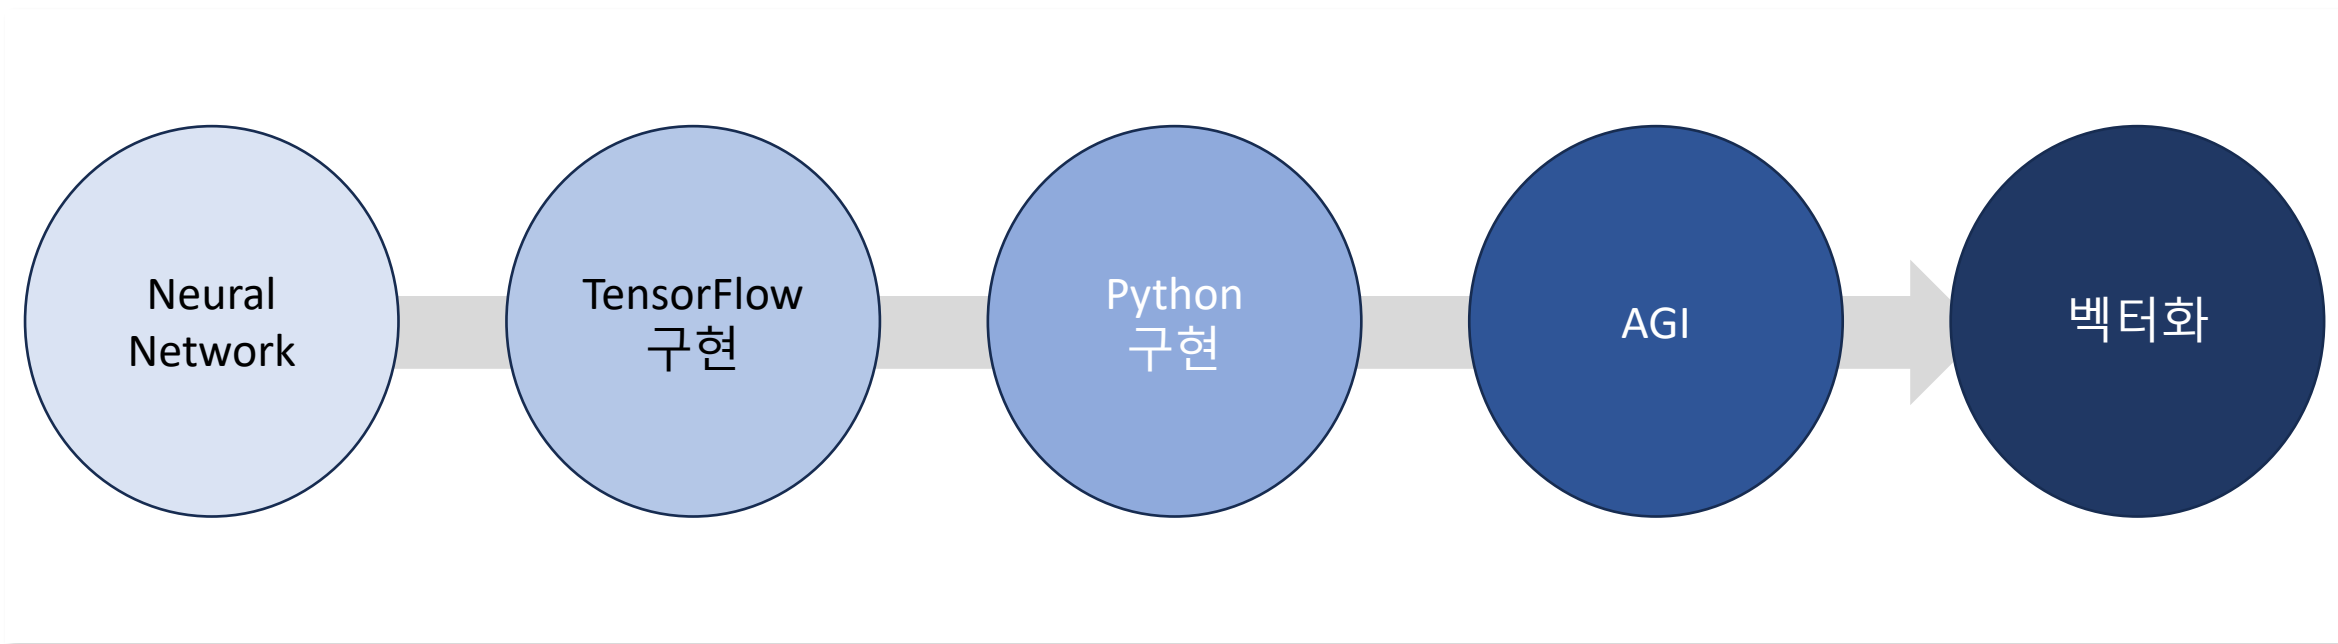
이번 주에는 신경망에 대해 알아보고 분류 작업에 신경망을 사용하는 방법을 알아봅니다. 텐서플로우 프레임워크를 사용해 몇 줄의 코드만으로 신경망을 구축할 수 있습니다. 그런 다음 Python에서 "처음부터" 자신만의 신경망을 코딩하는 방법을 배우며 더 깊이 파고듭니다. 선택 사항으로 병렬 처리(벡터화)를 사용하여 신경망 계산을 효율적으로 구현하는 방법에 대해 자세히 알아볼 수도 있습니다.

학습 목표


- 신경망의 다이어그램과 구성 요소에 익숙해지기
- 신경망에서 '레이어'의 개념 이해하기
- 신경망이 새로운 기능을 학습하는 방법을 이해합니다.
- 각 레이어에서 '활성화'가 계산되는 방식을 이해합니다.
- 신경망으로 이미지 분류를 수행하는 방법을 알아보세요.
- 프레임워크인 '텐서플로우'를 사용하여 이미지 분류를 위한 신경망을 구축합니다.
- TensorFlow의 신경망 레이어에서 데이터가 어떻게 들어오고 나가는지 알아보세요
- 일반 Python 코드로 신경망을 구축하여(처음부터) 예측을 수행합니다.
- (선택 사항): 신경망이 '병렬 처리(벡터화)'를 사용하여 계산을 더 빠르게 하는 방법을 알아보세요.

Introduction

1주차 : 신경망




Neural Networks




- 컴퓨터 비전
- 음성 인식
- 자연어처리

Neural Networks

What is Neural Networks?




Biological



Mathematical

Perceptron



Neural Networks

What is Neural Networks?

Artificial Neural Network(ANN)

- 적은 Hidden Layer
- Overfitting 문제
- 간단한 비선형 문제 해결




Deep Neural Network(DNN)

- Multi-Layer Perceptron(MLP)
- 여러 개의 Hidden Layers
- 복잡한 비선형 문제 해결



RNN, CNN, LSTM, GRU 등



딥러닝 모델의 Hidden Layer와 Node를 적절히 구성하여 Output값을 잘 예측하는 것

Neural Networks


Activation Function

- 입력 신호의 총합을 출력 신호로 변환하는 함수
- 앞 뉴런에서 자극이 들어왔을 때, 다음 뉴런을 활성화 할지 여부 판단
- 비선형 함수: 딥러닝 모델의 레이어 층을 깊게 가져가기 위함

Output Layer


Traditional Non-Linear Activation Functions

Sigmoid



$$y = 1 / (1 + e^{-x})$$

Hyperbolic Tangent




$$y = (e^x - e^{-x}) / (e^x + e^{-x})$$

Softmax

Hidden Layer


Modern Non-Linear Activation Functions

Rectified Linear Unit (ReLU)



$$y = \max(0, x)$$


Leaky ReLU



$$y = \max(\alpha x, x)$$

α = small const. (e.g. 0.1)

Exponential LU




$$y = \begin{cases} x, & x \geq 0 \\ \alpha(e^x - 1), & x < 0 \end{cases}$$

Neural Networks

Activation Function_Output Layer


- Sigmoid (Logistic)



- 이진분류
- 출력값 범위 : [0,1]
- 손실함수: binary_crossentropy
- **Vanishing Gradient Problem 문제**

➡
Generalization

- Softmax




- 다중분류 (N가지 출력)
- 출력값 범위 : [0,1]
- 단, 출력값 총합이 항상 1
- 손실함수: Categorical_crossentropy

Neural Networks


Activation Function_Hidden Layer

- ReLU




- 딥러닝에서 가장 많이 사용
- Vanishing Gradient 문제 해결
- 연산 속도 빠름
- **Dying ReLU 문제**
ReLU사용한 노드가 비활성화되는 현상
→ 0으로 출력

- Leaky ReLU



- ReLU의 Dying ReLU 문제를 해결하기 위한 시도
- 0으로 출력되던 부분을 아주 작은 음수값으로 출력

- ELU




- ReLU의 모든 장점을 포함
- Dying ReLU 문제를 해결

Neural Networks

Neural Network Layer




이진분류 -> Sigmoid 함수

$$g(z) = \frac{1}{1 + e^{-(z)}}$$



$$a_j^{[l]} = g(\vec{w}_j^{[l]} \cdot \vec{a}^{[l-1]} + b_j^{[l]})$$

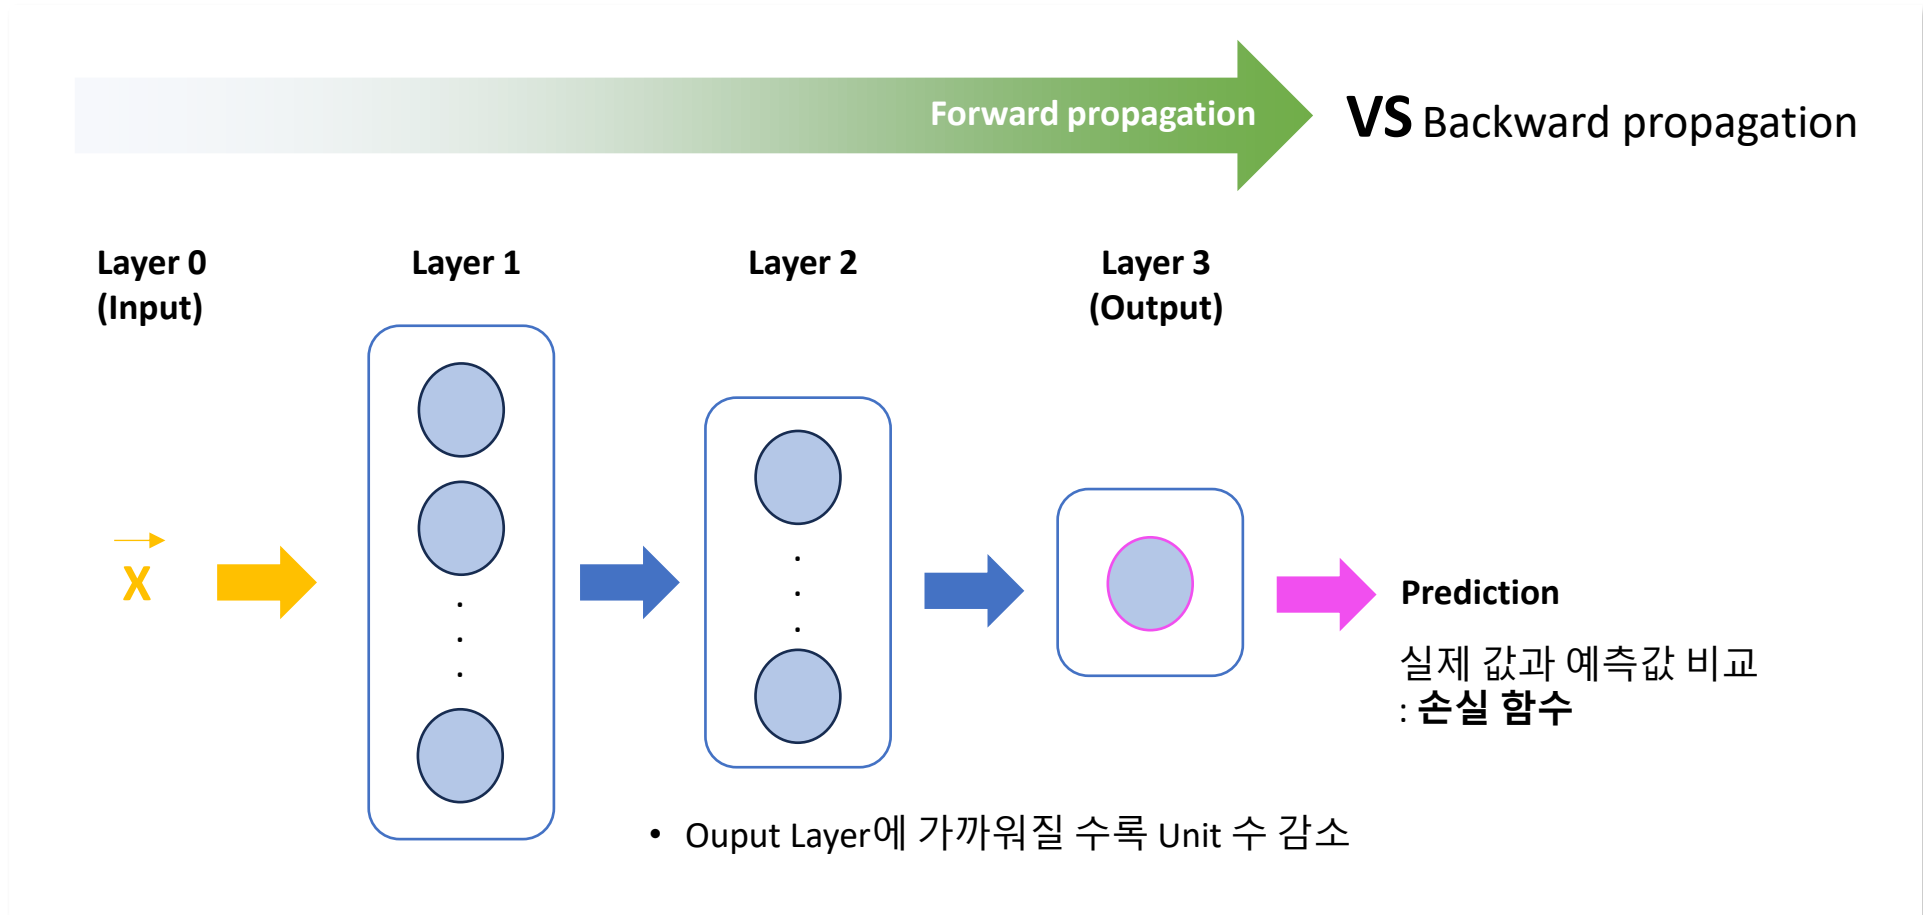
- a: Activation Value
 - l: Layer
 - j: Unit(neuron)
 - w: weight
 - b: bias
- parameters



Predict category 1 or 0 (yes/no)

Neural Networks

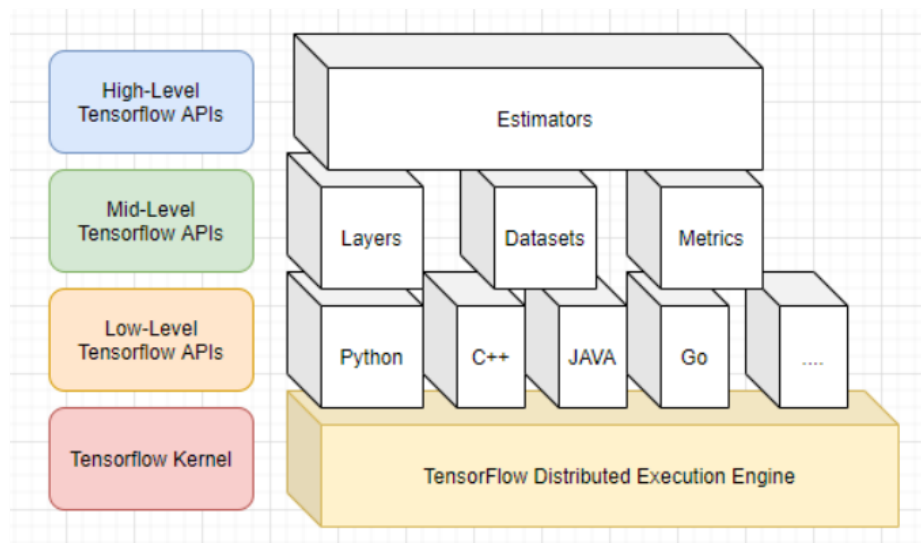
Forward Propagation



TensorFlow



- Google에서 개발한 딥러닝 라이브러리
- 사실상 거의 모든 딥러닝 프로젝트에서 범용적으로 활용



출처: 텐서플로우 홈페이지

프레임워크	동작	지원 단체	라이선스 종류	속도	범용성	개발/학습 난이도	참여자 규모
텐서플로우	파이썬, C++ 자바, etc	구글	아파치 2.0	++	++	++	+++
케라스	파이썬, R, MNNNet, DL4J	MIT	MIT 라이선스	+++	+++	+	+++
파이토치	파이썬, C++	페이스북	BSD	+++	+	+	++
DL4J	자바, 스칼라, 클로저, 파이썬, 코틀린	스카이라이프 DL4J 커뮤니티	아파치 2.0	++	+++	+++	+
카레	C++, 파이썬, 매트랩	버클리 대학 연구 팀	BSD	+	+	+++	+
MXNet	C++, 파이썬, 줄리아, 매트랩, 차버스크립트, 고, R, 스칼라, 쉘	아파치 재단, AWS	아파치 2.0	++	+++	++	++


출처: 테크월드뉴스

참고 페이지: <https://www.tensorflow.org/>

TensorFlow

TensorFlow 딥러닝 모델 구성

- Keras 패키지를 활용하여 직접 모델링



```
x = np.array([[0.0, ..., 245, ..., 240, ..., 0]])
layer_1 = Dense(units=25, activation='sigmoid')
a1 = layer_1(x)

layer_2 = Dense(units=15, activation='sigmoid')
a2 = layer_2(a1)

layer_3 = Dense(units=1, activation='sigmoid')
a3 = layer_3(a2)
```

- 모델 클래스 객체 생성

```
tf.keras.models.Sequential()
```

- 모델의 각 Layer 구성

```
tf.keras.layers.Dense(units, activation)
```

- 모델 구축 예시

```
model = tf.keras.models.Sequential([
    tf.keras.layers.Dense(10, input_dim=2, activation='sigmoid'),
    # 2개의 입력 변수, 10개의 노드
    tf.keras.layers.Dense(10, activation='sigmoid'), # 10개의 노드
    tf.keras.layers.Dense(1, activation='sigmoid'), # 1개의 노드,
    # 마지막 층에 노드 하나로 결과값 나옴. #(입력이 두 개, 출력이 하나, 히든 층 2개) ])
```

- 모델 학습

```
model.compile(loss='mean_squared_error', optimizer='SGD')

#dataset에 저장된 데이터를 입력하고, epochs를 100으로 설정하고 학습
model.fit(dataset, epochs=100)
```

- 예측

```
Model.predict()
```

TensorFlow

DNN 모델링 예제

누수 탐지 예측 모델 구현

- stratifiedKFold Cross validation 사용 → 오버피팅 해결
- 배치 정규화(Batch Normalization) → 오버피팅 해결
- hidden layer 10개
- 95퍼센트 분산을 설명하는 PCA로 주성분 74개 선택 (기존 독립변수 532개)
- 활성화함수: ReLU, Softmax
- 손실함수: categorical_crossentropy
- Optimizer : Adam

- 정확도: 0.9676

Epoch 100/100
571/571 ————— 2s 3ms/step - accuracy: 0.9854 - loss: 0.0509
1169
143/143 ————— 0s 1ms/step - accuracy: 0.9691 - loss: 0.1114
Accuracy: 0.9676

```
acf = 'relu'
Dropout_rate = 0.2

# K-Fold 교차 검증 설정
kfold = KFold(n_splits=10, shuffle=True, random_state=42)
cv_scores = []

# 교차 검증 루프
for train, val in kfold.split(X_train_pca):
    # 모델 구축
    model = Sequential()
    model.add(Dense(1024, input_dim=X_train_pca.shape[1], activation=acf))
    model.add(BatchNormalization())
    #model.add(Dropout(Dropout_rate))
    model.add(Dense(1024, activation=acf))
    #model.add(Dropout(Dropout_rate))
    model.add(Dense(512, activation=acf))
    #model.add(Dropout(Dropout_rate))
    model.add(Dense(512, activation=acf))
    #model.add(Dropout(Dropout_rate))
    model.add(Dense(256, activation=acf))
    #model.add(Dropout(Dropout_rate))
    model.add(Dense(256, activation=acf))
    #model.add(Dropout(Dropout_rate))
    model.add(Dense(128, activation=acf))
    #model.add(Dropout(Dropout_rate))
    model.add(Dense(128, activation=acf))
    #model.add(Dropout(Dropout_rate))
    model.add(Dense(64, activation=acf))
    #model.add(Dropout(Dropout_rate))
    model.add(Dense(64, activation=acf))
    #model.add(Dropout(Dropout_rate))
    model.add(Dense(y_categorical.shape[1], activation='softmax'))

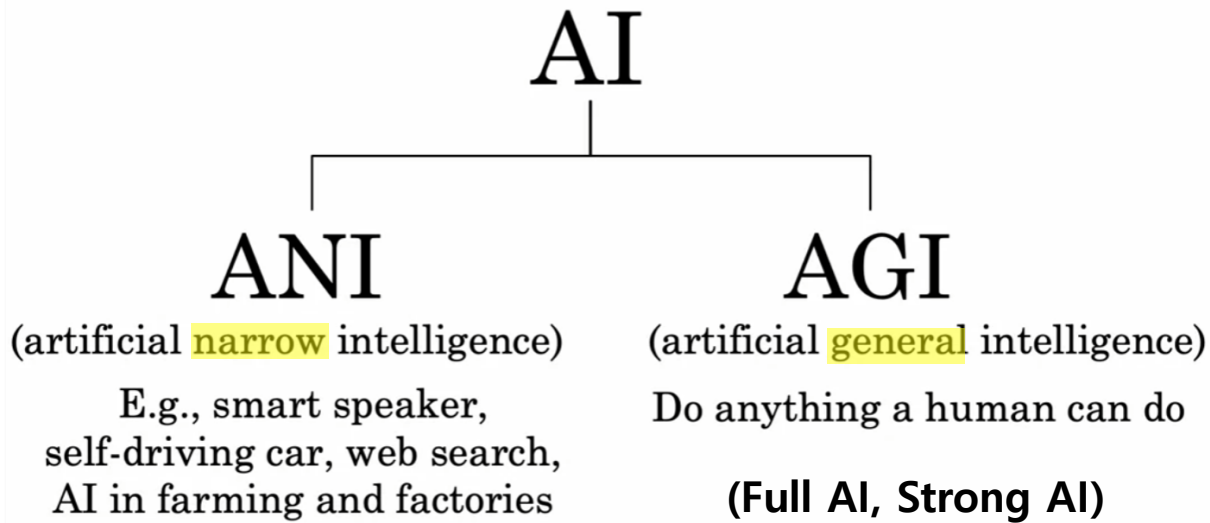
# 모델 컴파일
model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])

# 모델 학습
model.fit(X_train_pca, y_train, validation_data=(X_test_pca, y_test), epochs=100, batch_size=32)



# 모델 평가
loss, accuracy = model.evaluate(X_test_pca, y_test)
print(f'Accuracy: {accuracy:.4f}')
```

Artificial General Intelligence(AGI)

What is AGI?



인간 수준의 인지적 문제 해결 능력



Artificial General Intelligence(AGI)

AGI vs ANI

구분	인공 일반 지능(AGI)	특정 목적 인공지능(Narrow AI)
정의	인간과 유사한 지능 수준을 보이는 인공지능	한정된 작업이나 분야에서 특화된 지능 보이는 인공지능
능력	학습, 이해, 추론, 문제 등 인간 지능의 전반적인 기능을 모방	특정 작업에 최적화된 기능 수행
적용 범위	다양한 분야에 걸쳐 유연하게 적용	매우 한정된 범위의 작업이나 문제에만 적용 가능
자율성	인간과 같은 수준의 자율적 의사 결정 능력	사전에 프로그래밍된 규칙이나 데이터에 기반한 의사 결정만 수행
학습 능력	제한된 데이터로부터 일반화된 지식을 학습하고 새로운 상황에 적용	대량의 데이터나 특정 작업에 특화된 학습을 통해 최적화
창의성	새로운 문제를 해결하거나 창의적 작업을 수행할 수 있는 잠재력	주어진 문제 해결에 초점을 맞추며 창의적 작업 수행은 제한적
사회 윤리적 영향	인간 사회 전반에 광범위한 영향을 미칠 가능성	특정 분야에서의 영향력은 크지만, AGI만큼 전반적인 영향력은 미미

AGI 개발에 필요한 주요 기술들

딥러닝 & 머신러닝

자연어 처리

컴퓨터 비전

로보틱스

추론과 결정

심리 인식 & 사회적 지능

출처: 삼성 SDS Inside Report

Position: Levels of AGI for Operationalizing Progress on the Path to AGI

Meredith Ringel Morris¹ Jascha Sohl-Dickstein² Noah Fiedel² Tris Warkentin² Allan Dafoe³
Aleksandra Faust² Clement Farabet³ Shane Legg³

Performance (rows) x Generality (columns)	Narrow <i>clearly scoped task or set of tasks</i>	General <i>wide range of non-physical tasks, including metacognitive tasks like learning new skills</i>
	특정 목적	일반적
Level 0: No AI	Narrow Non-AI calculator software; compiler	General Non-AI human-in-the-loop computing, e.g., Amazon Mechanical Turk
Level 1: Emerging <i>equal to or somewhat better than an unskilled human</i>	Emerging Narrow AI GOF AI (Boden, 2014); simple rule-based systems, e.g., SHRDLU (Winograd, 1971)	Emerging AGI ChatGPT (OpenAI, 2023), Bard (Anil et al., 2023), Llama 2 (Touvron et al., 2023), Gemini (Pichai & Hassabis, 2023)
Level 2: Competent <i>at least 50th percentile of skilled adults</i>	Competent Narrow AI toxicity detectors such as Jigsaw (Das et al., 2022); Smart Speakers such as Siri (Apple), Alexa (Amazon), or Google Assistant (Google); VQA systems such as PaLI (Chen et al., 2023); Watson (IBM); SOTA LLMs for a subset of tasks (e.g., short essay writing, simple coding)	Competent AGI not yet achieved
Level 3: Expert <i>at least 90th percentile of skilled adults</i>	Expert Narrow AI spelling & grammar checkers such as Grammarly (Grammarly, 2023); generative image models such as Imagen (Saharia et al., 2022) or Dall-E 2 (Ramesh et al., 2022)	Expert AGI not yet achieved
Level 4: Virtuoso <i>at least 99th percentile of skilled adults</i>	Virtuoso Narrow AI Deep Blue (Campbell et al., 2002), AlphaGo (Silver et al., 2016; 2017)	Virtuoso AGI not yet achieved
Level 5: Superhuman <i>outperforms 100% of humans</i>	Superhuman Narrow AI AlphaFold (Jumper et al., 2021; Varadi et al., 2021), AlphaZero (Silver et al., 2018), Stockfish (Stockfish, 2023)	Artificial Superintelligence (ASI) not yet achieved

출처: Position: Levels of AGI for Operationalizing Progress on the Path to AGI.2024.07

Artificial General Intelligence(AGI)

AGI의 등장



Jensen Huang (NVIDIA CEO)

“AGI 시대 5년 남았다”

(‘GTC 24’. 2024.03)

VS



Andrew Ng (Stanford Professor)

“AGI는 적어도 30~50년 이상 걸린다”

(‘초거대 AI모델 플랫폼 최적화 센터 초청 강연’. 2023.07)

Artificial General Intelligence(AGI)

AGI의 영향

실현가능성

- Google, Open AI, Meta, Amazon 등 여러 거대기업이 개발에 참여
- 전문가마다 등장 시기에 대한 의견이 다름
- 산업계에서는 비교적 빠른 기간 내에 실현 가능하다는 의견


영향

- 인간이 살아가는 전반적인 방식에 영향을 미침
- 국가간 외교 문제
- 시장의 경쟁 양상

→ 관련 규제가 필요하다는 의견 多

윤리적/사회적 요인에 결정 될 것

인공지능(AGI)의 윤리적 문제 – ‘AI 일자리 대체’



Andrew Ng

“AI에 대한 두려움 및 위험성이 과장되어 있음”
“인간은 AI를 통제할 능력이 있음”
“AI가 인간의 일자리를 소멸시키는 것이 아닌,
AI를 활용할 수 있는 사람이 그렇지 못한 사람을 대체할 것”

(2024.04)

Vectorization

Vectorization 코드 비교

- For Loops

```
x = np.array([200, 17])
W = np.array([[1, -3, 5],
              [-2, 4, -6]])
b = np.array([-1, 1, 2])
```

```
def dense(a_in, W, b):
    units = W.shape[1]
    a_out = np.zeros(units)
    for j in range(units):
        w = W[:, j]
        z = np.dot(w, a_in) + b[j]
        a_out[j] = g(z)
    return a_out
```

For문

[1, 0, 1]

- Vectorization

```
X = np.array([200, 17])
W = np.array([[1, -3, 5],
              [-2, 4, -6]])
B = np.array([-1, 1, 2])
```

2D array

same

1x3 2D array

```
def dense(A_in, W, B):
    Z = np.matmul(A_in, W) + B
    A_out = g(Z)
    return A_out
```

벡터화

matrix multiplication

- Numpy의 `matmul` 함수 사용 -> 행렬곱

➡ 효율적인 신경망 구현

- 행렬 곱셈

7.2 Matrix Multiplication

Multiplication of a Matrix by a Matrix

The product $C = AB$ (in this order) of an $m \times n$ matrix $A = [a_{jk}]$ times an $n \times p$ matrix $B = [b_{jk}]$ is defined if and only if $r = n$ and is then the $m \times p$ matrix $C = [c_{jk}]$ with entries

$$(1) \quad c_{jk} = \sum_{l=1}^n a_{jl}b_{lk} = a_{j1}b_{1k} + a_{j2}b_{2k} + \cdots + a_{jn}b_{nk} \quad \begin{matrix} j = 1, \dots, m \\ k = 1, \dots, p. \end{matrix}$$

$$\begin{matrix} A & B & = & C \\ [m \times n] & [n \times p] & = & [m \times p] \end{matrix}$$

Multiplication of rows into columns

$$m=4 \left\{ \begin{matrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \\ a_{41} & a_{42} & a_{43} \end{matrix} \right\} \begin{matrix} p=2 \\ \left\{ \begin{matrix} b_{11} & b_{12} \\ b_{21} & b_{22} \\ b_{31} & b_{32} \end{matrix} \right\} \end{matrix} = \begin{matrix} p=2 \\ \left\{ \begin{matrix} c_{11} & c_{12} \\ c_{21} & c_{22} \\ c_{31} & c_{32} \\ c_{41} & c_{42} \end{matrix} \right\} \end{matrix} \right\} m=4$$
$$c_{21} = a_{21}b_{11} + a_{22}b_{21} + \cdots + a_{2n}b_{n1}$$

Paper Review

Application of Deep Learning

Ahmed, S. F., Alam, M. S. B., Hassan, M., Rozbu, M. R., Ishtiak, T., Rafa, N., ... & Gandomi, A. H. (2023). Deep learning modelling techniques: current progress, applications, advantages, and challenges. *Artificial Intelligence Review*, 56(11), 13521-13617.



2023.04

Taye, M. M. (2023). Understanding of machine learning with deep learning: architectures, workflow, applications and future directions. *Computers*, 12(5), 91.



2023.04



Sharifani, K., & Amini, M. (2023). Machine learning and deep learning: A review of methods and applications. *World Information Technology and Engineering Journal*, 10(07), 3897-3904.



2023.05

Paper Review

Deep learning modelling techniques: current progress, applications, advantages, and challenges

Artificial Intelligence Review (2023) 56:13521–13617 https://doi.org/10.1007/s10462-023-10466-8	
Deep learning modelling techniques: current progress, applications, advantages, and challenges	
Shams Forruque Ahmed ¹ · Md. Sakib Bin Alam ² · Maruf Hassan ¹ · Mahtabin Rodela Rozbu ³ · Taoseef Ishtiaq ⁴ · Nazifa Rafa ⁵ · M. Mofijur ^{6,7} · A. B. M. Shawkat Ali ^{8,9} · Amir H. Gandomi ^{10,11} 	
Published online: 17 April 2023 © The Author(s) 2023	
Abstract Deep learning (DL) is revolutionizing evidence-based decision-making techniques that can be applied across various sectors. Specifically, it possesses the ability to utilize two or more levels of non-linear feature transformation of the given data via representation learning in order to overcome limitations posed by large datasets. As a multidisciplinary field that is survey DL architectures encompassing the full scope of DL, this paper comprehensively reviews the state-of-art DL insights into their advantages and challenges. It was it a highly domain-specific efficiency and could be ever, training DL models can be very time-consuming for better accuracy. Since DL is also susceptible to get stuck on local minima, improved DL to create more robust models. Regardless, DL has results in the healthcare, education, security, comment sectors. Some models, like the convolutional neural networks (CNN), recurrent neural network (RNN) autoencoders, are frequently used, while the potential challenges experienced by conventional models may dominate future DL models, this work aimed to involved in the development and use of DL models in	
Deep learning models	Advantages
Vector space model (VSM)	<ul style="list-style-type: none">- Ranks retrieved documents by identifying and rating the most relevant text documents for a specific query- Identifies similar files among distinct documents, and thus assists to detect plagiarism- Simple in structure as it is constructed on the basis of linear algebra- Permits for partial matching- Term weights are not binary- Allows for the computation of the similarity degree between documents and queries on a continuous scale
Convolutional neural network (CNN)	<ul style="list-style-type: none">- Feature engineering is a time-consuming and complicated process used traditionally in image processing that is not required in CNN- The models are considered robust under different challenging circumstances such as complex background, system overfitting and size, various resolutions, and illumination- After training, the efficiency of testing time is substantially higher than that of other approaches including VSM- Requires less time in classification- Without human supervision, automatically can detect critical parameters- High precision in the problems of image recognition
Recurrent neural network (RNN)	<ul style="list-style-type: none">- While are frequently used in conjunction with convolutional layers to extend the effective input neighborhood- It is advantageous in forecasting time series since the highlight point works as a reminder of previous inputs
Challenges	
<ul style="list-style-type: none">- Textual VSM is incapable of coping with linguistic ambiguity and variety- Technically, terms are assumed to be statistically independent- In the presentation of vector space, the order of the terms that appeared in the documents is lost- Keywords search must exactly match the terms in the documents, even substrings can lead to search of "false positives"- Due to their low similarity values, long documents/papers are poorly represented- Suffers from polysemy and synonym- The process of weighting is intuitive, although it is not very much formal- Sensitivity to semantic changes with a similar context and a distance from vocabulary will not be associated, causing a month of "false negatives"- Poor data labelling, which can significantly reduce system performance and accuracy- Comparatively larger data sets are required to train, as well as correct annotation, which requires domain expertise- Optimization challenges arising from the complexity of the models, and hardware limitations- Sometimes take a longer time to train data- Computational cost is high- Takes more time to train using a GPU- Suffers from gradient vanishing/exploding problem, which limits longer sequences- Unable to stack up	
Extended author information available on the last page of the article	
	

연도: 2023.04

연구목적

딥러닝 모델링 기술에 대한 현황을 포괄적으로 리뷰하고, 다양한 응용 분야에서의 진전, 장점, 도전과제를 탐구하기 위함. 또한, 현재 딥러닝의 한계와 문제점을 해결할 수 있는 방법을 제안, 미래 딥러닝 모델의 발전 방향을 제시.

연구방법

문헌 분석 방법을 사용하여 데이터베이스에서 186,000개의 논문을 검토하였고, 최종적으로 419개의 논문을 분석 → 최신 알고리즘과 모델링 기술을 중심으로 평가, 분석 수행

요약

- 4장 - 다양한 유형의 딥러닝 모델 구조, 최신 동향 등 설명, 모델별 장점 & 도전과제 테이블 제시
- 6장 - 모델링 기법들이 어떤 연구에 활용될 수 있는지 비교 분석 (RNN = 시계열 예측에 유용)
- 7장 - 딥러닝의 미래:
 - 하드웨어 및 소프트웨어 시스템의 발전
 - 크고 광범위한 데이터세트의 필요성
 - 다양한 도메인에서의 적용 - 모델의 일반화 능력을 증진

Paper Review

Machine Learning and Deep Learning: A Review of Methods and Applications





TRAIN AND TEST